

Franck Delmas

AI Engineer · Architecte Systèmes Distribués · Multi-GPU

Orchestration multi-agents · Infrastructure IA on-premise · Freelance / Mission longue

✉ miningexpert31@gmail.com

🔗 github.com/Turbo31150

📍 France (remote / déplacement)

TJM cible : 550-700 €/j

928 Agents IA

6 GPUs / 46GB VRAM

44 Repos GitHub

Mission 18 mois

CHIFFRES CLÉS

928+

AGENTS IA
ACTIFS

6

GPUS NVIDIA

<300ms

LATENCE
VOCALE

835

PIPELINES
AUTO

144+

OUTILS MCP

€21k

ÉCONOMIE/AN
CLOUD

STACK TECHNIQUE

LANGAGES

Python

TypeScript

Bash

JavaScript

IA / LLM / ORCHESTRATION

LangChain

MCP Protocol

Claude SDK

LM Studio

Ollama

vLLM

DeepSeek-R1

Multi-agent

INFRASTRUCTURE / CLOUD

Docker Swarm

Docker Compose

Linux

systemd

CUDA

NVIDIA

FastAPI

WebSocket

DATA / BASES DE DONNÉES

PostgreSQL

Redis

SQLite3

Elasticsearch

SQLAlchemy

VOICE / REAL-TIME

Whisper CUDA

faster-whisper

Silero VAD

PyAudio

ElevenLabs

PROFIL

Ingénieur IA indépendant spécialisé dans la conception et l'opération de systèmes distribués multi-GPU. Auteur de **JARVIS OS v17.0** — un OS IA autonome orchestrant 928 agents sur 6 GPUs avec 835 pipelines self-healing. Expert en orchestration multi-LLM, pipelines temps réel et infrastructure on-premise à coût minimal. Approche R&D : itérations rapides, métriques mesurables, zéro dépendance cloud.

PORTFOLIO — PROJETS GITHUB

ReactNode.jsWebSocket

ADÉQUATION FLAIR GROUP

- **IA & Data**
Expert — JARVIS OS, TradeOracle
- **Innovation R&D**
Expert — multi-agent, MCP, LLM
- **Infrastructure Cloud**
Solide — Docker Swarm, GPU
- **Développement Agile**
Solide — 570+ QA scripts
- **Cybersécurité**
Partiel — secrets mgmt, on-premise

DISPONIBILITÉ

Disponible

Mission freelance 18 mois
ou CDI client final

550-700 €/j TJM

JARVIS OS v17.0

🏠 jarvis-linux

OS IA autonome — Projet flagship · Score Claude Code 98/100

Système d'exploitation IA distribué en 9 couches cognitives, orchestrant 928+ agents spécialisés sur un cluster 6 GPUs / 46GB VRAM. Zero cloud dependency — traitement 100% on-premise. Interface voice-first avec pipeline CUDA <300ms. 835 chaînes d'automation self-healing, 144+ outils MCP exposés, 2 658 commandes vocales nativement reconnues.

928+46GB8352 658

AGENTS ACTIFSVRAM GPUPIPELINES AUTOCOMMANDES VOCALES

91.4%
PYTHON CODEBASE

- L1

Hardware

6x NVIDIA GPU, CUDA, cluster 3 machines
- L2

OS

Ubuntu/Debian optimisé, systemd
- L3

Data

SQLite3 distribué synchronisé
- L4

Inférence

LM Studio · Ollama · vLLM · load balancing
- L5

Protocole

144+ MCP handlers
- L6

Agents

928 agents spécialisés
- L7

Orchestration

Claude Agent SDK · consensus voting
- L8

Pipeline

n8n · Python · self-healing chains
- L9

Interface

Voice CUDA · WebSocket dashboard

PythonCUDA LM StudioOllama vLLM MCP Claude SDK
SQLite3 Docker WebSocket FastAPI n8n

JARVIS-CLUSTER — La Créatrice

🏠 JARVIS-CLUSTER

Infra GPU distribuée · Docker Swarm · 3 nœuds physiques

Infrastructure multi-nœuds orchestrant 3 machines physiques (M1 Master 6 GPUs, M2 Detector, M3 Orchestrator) via Docker Swarm. Pipeline de dispatch en 9 étapes avec failover adaptatif, circuit breaker, monitoring thermique GPU et endpoints OpenAI-compatibles. ROI : breakeven vs cloud en <3 mois.

39€30/mois

NŒUDS PHYSIQUESÉTAPES DISPATCHCOÛT OPÉRATIONNEL

€21k/an
ÉCONOMIE VS CLOUD

Docker SwarmPython FastAPI WebSocket systemd Linux
GPU ThermalCircuit Breaker OpenAI API

TradeOracle

[TradeOracle](#)

Trading crypto autonome · Multi-LLM consensus · MEXC Futures

Agent de trading crypto autonome exécutant des futures sur 800+ paires MEXC via un système de consensus multi-modèles (Domino Pipeline). Score composite 70/100 requis avant exécution. Risk management 3-tier avec TP à +1.5%, +3%, +7% et SL à -1.2%. Dashboard temps réel FastAPI + WebSocket.

800+

PAIRES CRYPTO

62%

WIN RATE BREAKOUT

40+

OUTILS MCP

3 LLM

CONSENSUS VOTING

Python

LangChain

FastAPI

Gemini 3.0

LM Studio

MCP

SQLAlchemy

MEXC API

WebSocket

jarvis-whisper-flow

[jarvis-whisper-flow](#)

STT CUDA temps réel · Privacy-first · 99+ langues

Pipeline speech-to-text on-premise avec faster-whisper + CUDA. Latence <300ms sur RTX 3060, WER 3.2% (large-v3). Détection d'activité vocale Silero VAD, 26 commandes intégrées, hot-reload des skills sans restart. 100% local, aucune donnée envoyée à un tiers.

<300ms

LATENCE RTX 3060

3.2%

WER LARGE-V3

99+

LANGUES SUPPORTÉES

26

COMMANDES VOCALES

faster-whisper

CUDA

Silero VAD

PyAudio

Docker

NVIDIA toolkit

PipeWire

Python

TradeOracle-Nexus-Elastic

[TradeOracle-Nexus-Elastic](#)

Plateforme analytique financière · Elasticsearch · Monte Carlo

Plateforme d'analyse financière avec backtesting Monte Carlo, indexation Elasticsearch des signaux de marché et pipeline de données haute fréquence. Visualisation temps réel des performances de stratégies de trading.

Elasticsearch

Python

Monte Carlo

Backtesting

FastAPI

SQLAlchemy

EXPÉRIENCE

AI Engineer Indépendant — Architecte Systèmes IA Distribués

Freelance · 2023 – présent · Remote / France

- ▶ Conception et déploiement de JARVIS OS : OS IA autonome orchestrant 928 agents sur cluster 6 GPUs
- ▶ Architecture multi-agent avec consensus LLM (Claude, Gemini, DeepSeek, modèles distillés)
- ▶ Infrastructure Docker Swarm multi-nœuds avec failover adaptatif et économie €21k/an vs cloud
- ▶ Développement de pipelines STT temps réel CUDA (latence <300ms, 3.2% WER)
- ▶ Système de trading crypto autonome multi-LLM sur 800+ paires MEXC Futures
- ▶ 44 repositories publics GitHub, 144+ outils MCP, 835 pipelines d'automation self-healing

Développeur Full Stack & Data Engineer

Missions antérieures · Python · FastAPI · React · PostgreSQL · Elasticsearch

- ▶ Développement d'APIs FastAPI avec WebSocket pour dashboards temps réel
- ▶ Pipelines ETL, indexation Elasticsearch, analytics Monte Carlo
- ▶ Automation navigateur (CDP Chrome DevTools Protocol)
- ▶ Déploiements Docker, monitoring GPU, scripting Linux/Bash

POURQUOI FLAIR GROUP — MISSION 18 MOIS

Ce que j'apporte

- ▶ Expertise IA rare sur le marché ESN
- ▶ Autonomie totale sur systèmes complexes
- ▶ Culture R&D + résultats mesurables
- ▶ Maîtrise complète du stack cloud/on-prem
- ▶ Engagement sur durée (projet JARVIS = 12+ mois)

Valeurs partagées (Flair)

- ▶ Transparence — code open-source, métriques publiques
- ▶ Engagement — 44 repos, contribution active
- ▶ Innovation — MCP Protocol, multi-agent (2024)
- ▶ Respect — documentation soignée, tests 570+

